Tema 8
Fundamentos lingüísticos del PLN: Representación y Procesamiento.

Procesamiento del Lenguaje Natural I
Grado en IA | Universidad de Alicante

Borja Navarro Colorado

26 de octubre de 2026

Outline

1. Concepto de lengua. Variedad lingüística en el mundo.
2. Un modelo teórico del texto.
3. Paradigmas de representación lingüística computacional.
4. Modelos de procesamiento computacional.
5. Conclusiones.

Introducción

- Qué son las lenguas
- Lenguas del mundo. Familias. Diferencias.
- Similitudes: los universales lingüísticos.

¿Qué son las lenguas?

- Sistema de comunicación convencional formado por signos lingüístico-verbales ("palabras" y su combinación) entendible por una comunidad.
  - Inglés, español, francés, euskera, etc.
  - La lengua es un consenso social. La delimintación entre lenguas es una cuestión no sólo lingüística (rasgos comunes, entendibilidad, ...) sino también social y política.

¿Qué son las lenguas?

- *Lenguaje*: capacidad humana innata para aprender y utilizar una o varias lenguas.
- Las *lenguas* son una manifestación de la facultad del lenguaje (Alonso-Cortés, p. 11)

Piensa...

¿Qué error conceptual hay en el título de la disciplina "Procesamiento del Lenguaje Natural"?

¿Qué son las lenguas?

- *Lenguaje*: capacidad humana innata para aprender y utilizar una o varias lenguas.
- Las *lenguas* son una manifestación de la facultad del lenguaje (Alonso-Cortés, p. 11)

Piensa...

¿Por qué un mono no puede generar textos y un ordenador sí?

¿Qué son las lenguas?

- *Lenguaje*: capacidad humana innata para aprender y utilizar una o varias lenguas.
- Las *lenguas* son una manifestación de la facultad del lenguaje (Alonso-Cortés, p. 11)

Piensa...

¿Por qué un mono no puede generar textos y un ordenador sí?

- Procesos cognitivos implicados en el lenguaje: secuenciación y combinación (Bernárdez 1999, p. 187)

¿Qué son las lenguas?

- Todas las lenguas se caracterizan por su *variabilidad*:
  - Variantes individuales (sexo, edad, formación, ...)
  - Variantes sociales (registro, región, ...)
- Pero todas las lenguas tienen unos rasgos comunes que nos permiten identificarlas como lenguas humanas, diferente de otros sonidos, de sonidos animales, etc.

  Por muchas diferencias que haya entre dos lenguas, ambas se reconocen como lenguas humanas.

Diversidad lingüística del mundo

Según rasgos comunes y origen, las lenguas se organizan en familias o tipos:

- *The World Atlas of Languages Structures*:

  `https://wals.info/`

- Ver mapa

Diversidad lingüística.

- Según orden sintático
  - Lenguas SVO
    (ESP) “Tu hermana bebe agua”
  - Lenguas VSO
    (ARA) الماء اختك تشرب
    (*Tashrabu ukhtuka al-ma’*)
    (bebe (ella) tu_hermana el_agua)
  - Lenguas SOV
    (LAT) “Soror tua aquam bibit”

Diversidad lingüística.

- Según presencia explícita o ausencia de sujeto:
  - Lenguas *pro-drop*:

    (ESP) "Llueve"
    (ESP) "Comí"
    (JAP) 食べた (*tabeta*)
  - Lenguas de sujeto obligatorio
    - (ENG)) "It rains'

Diversidad lingüística.

- Según marcan la transitividad:
  - Lenguas acusativas
    - El sujeto de las construcciones transitivas e intransitivas tienen las mismas marcas gramaticales.
      (ESP) "El hombre ha llegado"
      (ESP) "El hombre se ha comido el caramelo"
  - Lenguas ergativas:
    - El Sujeto de las construcciones intrasitivas tiene las mismas marcas gramaticales que el *objeto* de las construcciones transitivas.
      (EUS) "Gizona etorri da" (hombre-ABS llegar AUX)
      (EUS) "Gizona**k** gozokia jan du" (hombre-ERG caramelo-ABS comer AUX)

Diversidad lingüística

Y mil cosas más... Ante esta gran diversidad:

- La lingüística teórica:
  - estudia el lenguaje o capacidad lingüística humana: lo común de todas las lenguas;
  - estudia y describe los rasgos propios de cada lengua (gramática).
- El PLN desarrolla:
  - sistemas específicos de cada idioma,
  - sistemas multilingües, o
  - sistemas *independientes* del idioma.

Un modelo teórico del texto.

Modelo teórico del texto

Al comunicarnos mediante una lengua natural, lo que se generan son **textos**:

- Manifestación concreta de una lengua.
- Generado por una persona con una intención comunicativa definida, en un tiempo y espacio también concretos.
- Para que sea considerado *texto*, **debe ser interpretado por un humano**, también con una intención o propósito, más un conjunto de hipótesis y expectativas, en un tiempo y espacio concreto.

Modelo teórico del texto

En PLN, el texto:

- es la *entrada* de un sistema de procesamiento del lenguaje natural,
- y la *salida* de un sistema de generación (textual).

Modelo teórico del texto

En PLN, el texto:

- es la *entrada* de un sistema de procesamiento del lenguaje natural,
- y la *salida* de un sistema de generación (textual).

Para pensar

¿Hasta qué punto hoy día es necesario que un texto esté creado o interpretado por un humano para que se considere TEXTO?

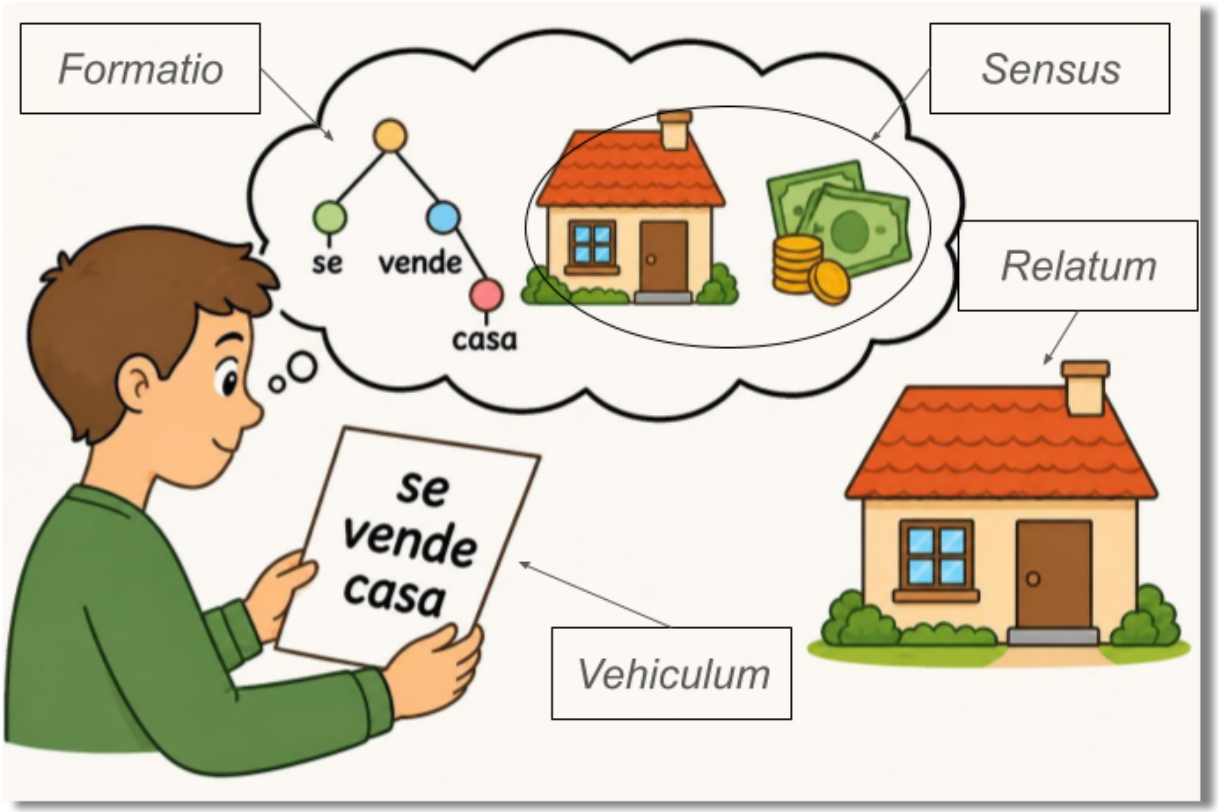
- Un *prompt* escrito para un LLM, ¿es un texto?
- Un "texto" generado por un LLM y procesado por otro LLM como agente autónomo, ¿es un texto?

Modelo teórico del texto

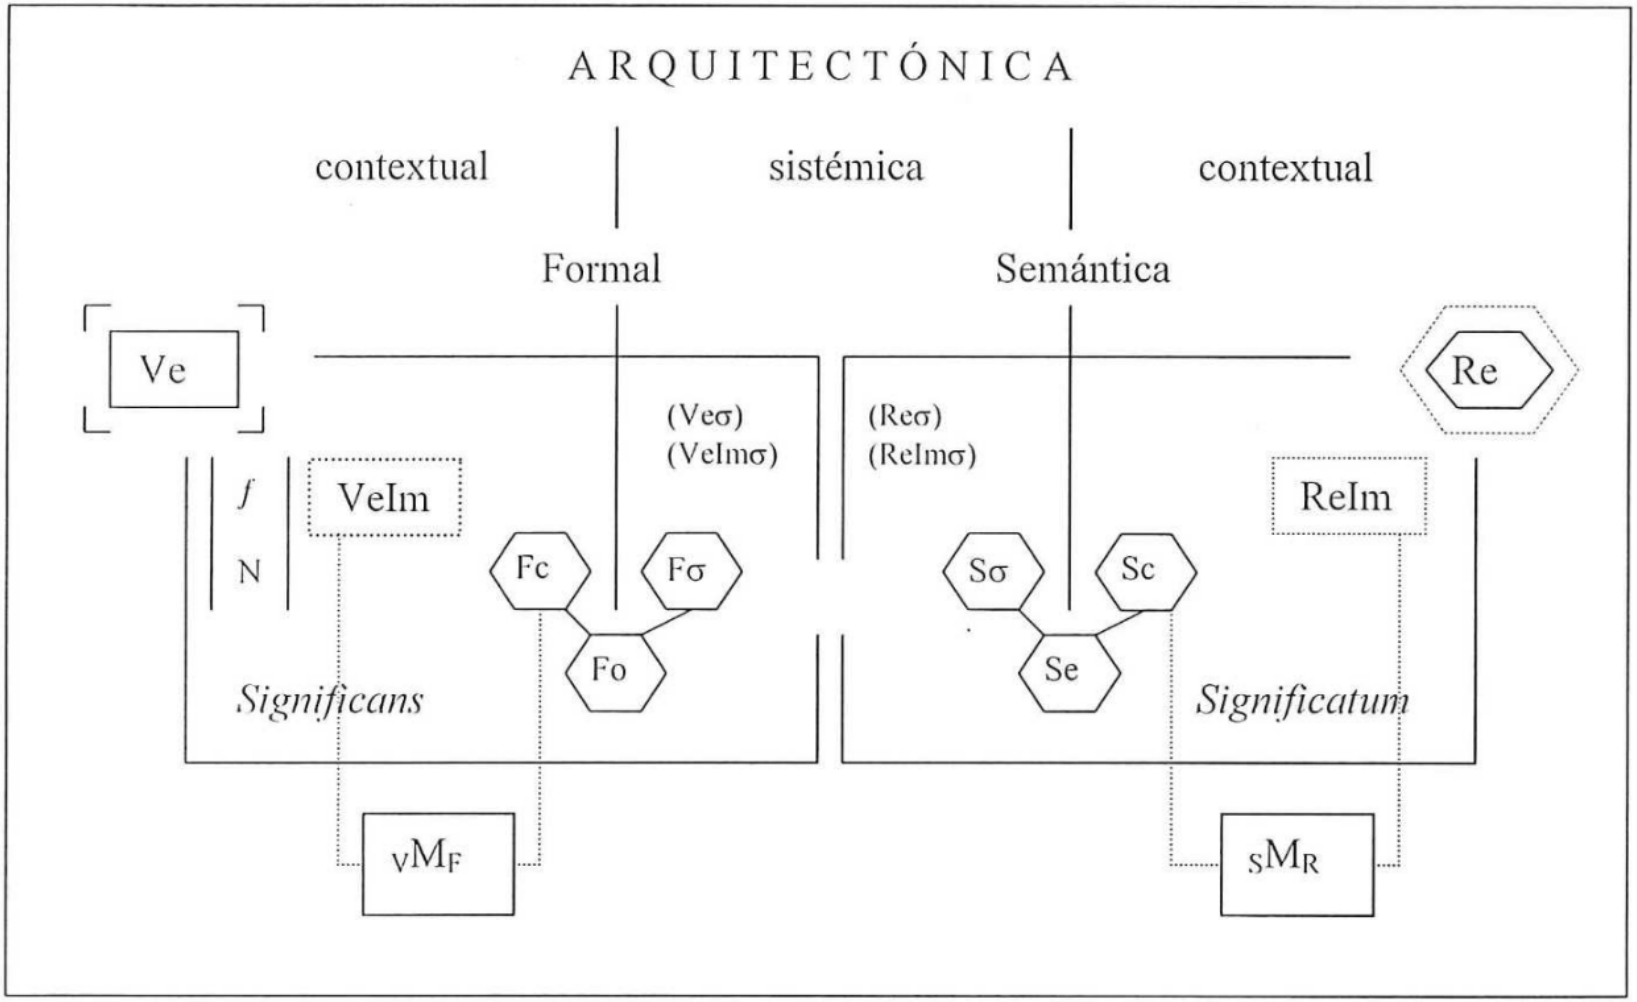
Componentes básicos de un texto (Petöfi 1991, 2004, Navarro 2001):

- *Vehiculum* (Ve): representación física del texto.
- *Formatio* (Fo): estructura formal.
- *Sensus* (Se): significado.
- *Relatum* (Re): referente extra-lingüístico.

Modelo teórico del texto



Modelo teórico del texto



Modelo teórico del texto

donde:

- $VeIm$: es la imagen mental del *vehiculum*.
- f y N hacen referencia a si el texto tiene sistema notacional (N) o no (f).
- Fc y $F\sigma$ corresponden a la cara contextual (c) y sistémica (σ) de la *formatio*.
- Sc y $S\sigma$ corresponden a la cara contextual (c) y sistémica (σ) del *sensus*.
- $ReIm$: es la imagen mental del *relatum*.

Interpretación del texto

- El gran problema de la interpretación textual es que **todo texto es ambiguo** en mayor o menor medida.
- Toda ambigüedad es siempre semántica:
  - Un enunciado puede tener dos o más interpretaciones diferentes.
  - Un enunciado puede tener un sentido vago, difuso o simplemente no ser interpretable (carencia de coherencia).

Interpretación del texto

- Pero las causas pueden ser diversas:
  - la categorial gramatical de las palabras,
  - la estructura sintáctica de las oraciones,
  - la polisemia léxica,
  - aspectos pragmáticos,
  - etc.

Ejemplos de ambigüedad

Ambigüedad categorial

"Nunca he fumado solo un cigarro."

Ejemplos de ambigüedad

Ambigüedad categorial

"Nunca he fumado solo un cigarro."

- "solo" como adjetivo: "Siempre he fumado con amigos."
- "solo" como adverbio: "En realidad he fumado muchos."

Ejemplos de ambigüedad

Ambigüedad sintáctica

"Vi a tu hermano con los prismáticos."

- ¿Quién tiene los prismáticos, el que habla (sujeto) o "tu hermano" (objeto)?

Ejemplos de ambigüedad

Ambigüedad léxica

"Si no llevas cuidado quemarás toda la planta."

- ¿Qué se puede quemar, el piso o el ser vivo?

Ejemplos de ambigüedad

Ambigüedad léxica

"El gato está en el garaje."

- ¿El animal o la herramienta?

El proceso de interpretación

- Para resolver todas estas ambigüedades, el ser humano aplica conocimiento del mundo; del contexto situacional; hipótesis, intención y preferencias comunicativas; así como inferencias sobre el contexto discursivo.
- Los sistemas de PLN utilizan sobre todo el **contexto discursivo**: palabras anteriores y posteriores del término o fragmento ambiguo.
  - Ej. Mecanismo de atención de la arquitectura *transformers* (Vaswani et al 2017).
  - En menor medida, conocimiento del mundo (ontologías), conocimientos lingüístico (diccionarios), identificación de intención comunicativa (chatbots), conocimiento situacional (geolocalización, idioma, etc.)...

Representación y procesos

- Los sistemas de PLN no son emulaciones exactas de modelos cognitivos humanos, sino modelos adaptados al medio computacional.

Representación y procesos

- Los sistemas de PLN no son emulaciones exactas de modelos cognitivos humanos, sino modelos adaptados al medio computacional.
- En esencia, todo sistema de PLN debe dar respuesta a dos problemas básicos:
  1. **Representación formal**: Cómo se codifica la información lingüística y/o conceptual de forma no ambigua, de tal manera que pueda ser entendida y procesada por la máquina (sin ambigüedad).
  2. **Método de procesamiento**: Cómo se transforman los datos de entrada en representaciones conceptuales o en otros textos.

Modelos de representación formal

Modelos de representación formal

Dos paradigmas:

- Paradigma simbólico
- Paradigma conexionista

Uno y otro responden a una visión diferente de la cognición humana.

Paradigma simbólico

- Se basa en la hipótesis de que la mente humana trabaja con **símbolos**.
- **Características**:
  - Codificación de conocimiento lingüístico mediante **etiquetas explícita**: morfología, sintaxis, semántica, etc.
  - Modelos **transparentes y explicativos** para el ser humano.
  - Uso de lenguajes formales de representación como **XML**, **JSON** o formatos tabulares.
- **Problema**: el conocimiento lingüístico no es ni lógico ni matemático. Por su complejidad y ambigüedad es difícilmente formalizable. Toda representación lingüística formal es siempre parcial.

Paradigma simbólico

Ejemplo: *A Madrid iré este fin de semana* - Formato CONLL:

ID	FORM	LEMMA	UPOS	HEAD	DEPREL	WIKIDATA ID
1	A	a	ADP	2	case	
2	Madrid	Madrid	PROPN	3	obl	Q2807
3	iré	ir	VERB	0	root	
4	este	este	DET	5	det	
5	fin	fin	NOUN	3	obl	Q1147045
6	de	de	ADP	7	case	
7	semana	semana	NOUN	5	nmod	Q23387
8	.		PUNCT	3	punct	

Paradigma conexionista

- Es el modelo propio de las **Redes Neuronales Artificiales**.
- **Características**:
  - Representación mediante **sub-símbolos**: no hay relación directa entre un símbolo y un concepto o significado.
  - La información se procesa a un nivel sub-conceptual mediante **vectores**.
  - En la actualidad, esos vectores son una **representación** veraz **del significado** del texto (*word embeddings*).
  - Son muy eficaces desde punto de vista computacional. Paradigma dominante en la actualidad.
- **Problema**: Modelo opaco o "caja negra", difícil de explicar qué está representando cada vector y qué hace con la información cuando la procesa.

Paradigma conexionista

$$\vec{casa} = \begin{pmatrix} 0 & 0.003 & 0.2 & 0.3 & -0.004 & \cdots & n \end{pmatrix}$$

Figura: Ejemplo de vector semántico - Falso W2V

Modelos de procesamiento

Modelos de procesamiento

1. **Modelo racional**, basado en reglas de reescritura.
2. **Modelo empírico**, basado en técnicas de aprendizaje automático.
3. **Modelo neuronal**, basado en redes neuronales artificiales.
4. **Modelo cuántico**, basado en cúbits y circuitos cuánticos.

Modelo racional

- Basado en la creación explícita de **reglas de re-escritura de símbolos**.
- Las reglas transforman un símbolo en otro (ej. un token en su categoría gramatical).

  $$\texttt{iré} \rightarrow \texttt{ir} \rightarrow \texttt{VERB} \rightarrow 0 \rightarrow \texttt{root}$$

- Un conjunto de reglas forma una **gramática**.

Modelo racional

- **Ventaja**: Claridad, transparencia y control total del proceso de análisis o generación textual.
- Inspirado en la gramática generativo-transformacional de Chomsky, fue el paradigma dominante en PLN desde sus orígenes hasta los años 90 del siglo XX.
- Hoy día se utilizan para procesamiento lingüístico fino o para gestión de excepciones.

Modelo empírico

- También utiliza símbolos para representar la información y reglas para procesar el texto.
- A diferencia del modelo racional, las reglas se extraen mediante técnicas de **aprendizaje automático**, sobre todo **supervisado**:
  - Anotación manual de corpus con la información a procesar.
  - Proceso de aprendizaje: SVM, CRF, HMM o Naïve Bayes, entre los más utilizados en PLN.
  - *Active learning*: corrección de la anotación y reentrenamiento hasta maximizar la precisión.

Modelo empírico

- Ventajas:
  - Permite modelar gran cantidad de fenómenos lingüísticos.
  - Mejor tratamiento del contexto al permitir la incorporación de diferentes tipos de rasgos contextuales (*features*) en el análisis.
  - Mejor tratamiento de la ambigüedad al incorporar pesos estadísticos y probabilidades en el análisis.
- Problemas:
  - Dependencia de recursos creados a mano, siempre escasos porque su creación es lenta y complicada.
  - Límite en la capacidad de generalización difícil de superar.
  - Sobre-simplificación de los problemas lingüísticos.

Métodos neuronales

- Basados en **Redes Neuronales Artificiales**.
- Aplicación de **métodos de aprendizaje auto-supervisado**: técnicas supervisadas sobre corpus sin anotación (*plain texts*)
  - Técnica *skip-gram with negative sampling* (Mikolov et al 2013) con las que se crearon los Word2Vec y derivados (GloVe, Fasttext).
  - Vector que representa la semántica de cada palabra sin necesidad de marcar a mano su significado.
- Arquitectura *transformer* y mecanismo de atención (Vaswani et al 2017).
  - Permite procesar de manera eficiente las relaciones contextuales de largo alcance.
- Desarrollo de los LLM. Mejora espectacular en todas las tareas de PLN. Cambio de paradigma.

Métodos cuánticos

QNLP - Solo experimentación por ahora.

- Procesamiento de textos en ordenadores cuánticos, aunque hoy día se trabaja con simulaciones en máquinas convencionales.
- Representación de información mediante *qbits*, que permite representar espacios semánticos de altísima dimensión.
- Tratamiento de la polisemia léxica como superposición cuántica.
- Composicionalidad de vectores semánticos: tratamiento de relaciones semánticas como entrelazamiento en circuitos cuánticos (Coecke et al 2010).

Conclusiones

- Las lenguas son sistemas de comunicación muy complejos caracterizadas por su variabilidad.
- Los textos son complejos de procesar computacionalmente por su alto grado de ambigüedad.
- Los dos problemas fundamentales del PLN son la representacion formal de la información y las técnicas de procesamiento.
- El paradigma dominante actual es la representación conexionista (vectores semánticos) y procesamiento mediante redes neuronales.
- Pero no resuelve todos los problemas. Vías de desarrollo son los modelos neuro-simbólicos y los modelos cuánticos.

Conclusiones

Próximas clases

- Los modelos de procesamiento son los propios de la IA.
- Los próximos temas se presentarán fenómenos lingüísticos complejos y su modelado neuro-simbólico.

  Fenómenos para los que hoy día no hay solución definitiva.

Repaso lectura

Sequence Labeling for Parts of Speech and Named Entities

- Tareas básicas del PLN:
  - PoS tagging.
  - NER.
- Procesos básicos:
  - HMM.
  - CRF.

Bibliografía

- Alonso-Cortés, Ángel *Lingüística*, Madrid, Cátedra, 2008.
- Bernárdez, Enrique. *¿Qué son las lenguas?* Alianza editorial, 1999.
- Coecke, Bob; Mehrnoosh Sadrzadeh, Stephen Clark. "Mathematical Foundations for a Compositional Distributional Model of Meaning" arXiv:1003.4394 [cs.CL] `https://doi.org/10.48550/arXiv.1003.4394`
- Mikolov, Tomas; Ilya Sutskever, Kai Chen, Greg Corrado y Jeffrey Dean. "Distributed Representations of Words and Phrases and their Compositionality". En: *NeurIPS*. 2013. `http://arxiv.org/abs/1310.4546`.
- Navarro Colorado, Borja. *Introducción a la Textología Semiótica*, Universidad de Alicante, 2001.
- Petófi, János S. *Towards a semiotic theory of human communication (Text linguistics —Semiotic Textology)*, Szeged, Gold Press, 1991
- Petöfi, János S. *Scrittura e interpretazione : introduzione alla testologia semiotica dei testi verbali*. Roma, Carocci, 2004.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser e Illia Polosukhin. "Attention Is All You Need." *Advances in Neural Information Processing Systems* 30, 2017 `https://arxiv.org/abs/1706.03762`