Praćtica 2 - Reto 1
Extracción de personajes

Procesamiento del Lenguaje Natural 1
Grado en IA | Universidad de Alicante

Borja Navarro Colorado

26 de octubre de 2026

Reto 1

Dada una novela, crear un *script* en Python que detecte y marque en XML todas las menciones de personajes y agrupe, mediante un identificador único, aquellas que se refieran al mismo personaje.

Ejemplo

Entrada

En esto, descubrieron treinta o cuarenta molinos de viento que hay en aquel campo, y así como don Quijote los vio, dijo a su escudero:
- La ventura va guiando nuestras cosas mejor de lo que acertáramos a desear; porque ves allí, amigo Sancho Panza, donde se descubren treinta, o pocos más, desaforados gigantes (...)
-¿Qué gigantes? -dijo Sancho Panza.
-Aquéllos que allí ves -respondió su amo- de los brazos largos...

Ejemplo

Salida

En esto, descubrieron treinta o cuarenta molinos de viento, y así como <rs type="person" ref="#pr001"> don Quijote </rs> los vio, dijo a <rs type="person" ref="#pr002"> su escudero </rs>:
- (...) ves allí, amigo <rs type="person" ref="#pr002"> Sancho Panza </rs>, donde se descubren treinta, o pocos más, desaforados gigantes (...)
-¿Qué gigantes? -dijo <rs type="person" ref="#pr002"> Sancho Panza </rs>.
-Aquéllos que allí ves -respondió <rs type="person" ref="#pr001"> su amo </rs>- de los brazos largos...

Este reto no tiene una solución única y definitiva. Se puede abordar de diferentes maneras.
Vuestra tarea es proponer e implementar una posible solución, una propuesta para abordar el problema que cumpla con los siguientes requisitos:

Menciones a personajes

> *Referring to characters in texts occurs with the use of* ***proper names, definite descriptions and personal pronouns*** *(Margolin 1995: 374). In addition to these direct references, indirect evocations can be found: the untagged rendering of direct speech, the description of actions (e.g. "a hand grabbed") or use of the passive voice ("the window was opened").*

Janidis, Fotis (2013) "Characters" en *The living handbook of narratology*. `https://www-archiv.fdm.uni-hamburg.de/lhn/node/41.html`

Menciones a personajes

Sólo hay que marcar referencias a personajes directas y explícitas:

- Nombres propios: nombre, apellidos, diminutivos, nombres familiares...
- Sintagma nominal definido: `la joven, el amigo, su hermano, ...`

  Solo la primera vez que se menciona al personaje puede ser SN indefinido: `un joven, una amiga...`
- Pronombres personales tónicos.

  Los átonos no los tratamos por ahora para evitar problemas de segmentación: `viéndole, pregúntales...`

Tareas PLN implicadas

Este reto combina dos tareas de PLN:

- ***Named Entity Recognition* (NER)** tipo PERSONA.
- Resolución de la correferencia (***Coreference Resolution***): detectar cuándo dos expresiones remiten al mismo referente (en este caso a un personaje):
  - **Resolución de anáforas**: cuando la expresión referencial es un pronombre o un SN definido que remiten a un referente ya mencionado en el texto (antecedente).

Más información en Jurafsky & Martin (2026) Chap. 24 "Coreference Resolution and Entity Linking" *Speech and Language Processing* `https://web.stanford.edu/~jurafsky/slp3/24.pdf`

Formalización

- Lenguaje de marcado XML siguiendo el estándar TEI:

  `https://tei-c.org/release/doc/tei-p5-doc/en/html/index.html`

- Etiqueta `<rs type="person" ref="#pr001">`, donde:
  - `rs` indica *referencing string*: `https://tei-c.org/release/doc/tei-p5-doc/en/html/ref-rs.html`
  - `type="person"` idica que es tipo PERSONA
  - `ref="#pr001"` es el ID único de ese personaje. Debe ser el mismo para todas las menciones al mismo personaje (correferencia). El resto de personajes será `"#pr002"`, `"#pr003"`, etc.

Actividad previa

Detección manual de las menciones de personajes del inicio de esta novela:

- Gertrudis Gómez de Avellaneda *Sab* 1841.

  `https://distantreading.github.io/ELTeC/spa/SPA1021.html`

- Por parejas, leed los primeros párrafos y marcar a mano cada mención de personaje.
- Puesta en común y acuerdo entre anotadores.

Requisitos

- Debe ser un *script* en Python que funcione en un cuaderno Google COLAB.
- Debe cargar la novela *Sab* desde esta url: `https://raw.githubusercontent.com/COST-ELTeC/ELTeC-spa/refs/heads/master/level1/SPA1021_GomezDeAvellaneda_Sab.xml`

Requisitos

- La novela está marcada en XML-TEI. Debe procesar solo los capítulos. Cada capítulo está marcado con la etiqueta `<div type="chapter" n="SPA1021001">`, donde los tres últimos digitos de `@n` indican el número de capítulo (001, 002, 003, etc.)
- La salida debe ser un fichero XML igual que la entrada, pero con la mención a cada personajes marcada como se ha explicado antes. Ese fichero debe llamarse "SPA1021_GomezDeAvellaneda_Sab_AnotadoXYZ.xml", donde XYZ son vuestros apellidos.
- En el cuaderno COLAB, en las celdas de texto, debéis explicar y **justificar** la aproximación propuesta.

Realización y entrega

- Se debe realizar en equipos de 3 ó 4 personas (los mismos equipos que ya tenéis hechos).
- en principio durante las horas de clase de prácticas (dos clases, 4 horas aprox.).
- Entregad por UA-Cloud el enlace al cuaderno COLAB con permiso para poder procesarlo.

Rúbrica de evaluación

Criterios:	**0**	**1**	**2∼4**	**5**
Funcionamiento	El *script* no funciona.	El XML no se ajusta al *Gold Standard*.	El XML se ajusta solo en parte *Gold Standard*.	El XML es muy similar al *Gold Standard*.
Aproximación	No justificada.	Muy simple.	Presenta cierto grado de madurez y/o originalidad.	Propuesta muy madura y/o original con un profundo conocimientos del problema.

Algunos recursos útiles

- Para procesar XML desde Python:
  - xml.etree.ElementTree
  - lxml
  - Beautiful Soup...
- Corpus NER español:
  - CoNLL-2002, Ancora-es, Capitel (IberLEF), MultiNERD...
- Herramientas NER en español:
  - SpaCy, Stanza, Freeling, FLAIR...
  - Varios modelos en HuggingFace...

Algunos recursos útiles

- Resolución de la correferencia:
  - Stanza
    `https://stanfordnlp.github.io/stanza/coref.html`
  - SpaCy `https://spacy.io/api/coref/`
  - Hay algunos modelos en HuggingFace como:
    - `https://github.com/huggingface/neuralcoref`
    - `https://huggingface.co/biu-nlp/f-coref`
    - `https://github.com/NeuroSYS-pl/coreference-resolution`
    - ...